



UE INGÉNIERIE DES DONNÉES · AMA

TD/TP · 3 h · 8 notebooks · 5 sources



PostgreSQL



MongoDB



Python



DuckDB



Jupyter



GitHub

Sources de données : le TP

Se connecter, récupérer, enregistrer proprement : PostgreSQL, MongoDB, fichiers open data, API REST et web.



Abraham Koloboe

Cloud Data Engineer

Outils du TP : DataGrip · Python · Jupyter · DuckDB · GitHub

Hier, on a compris. Aujourd'hui, on récupère pour de vrai.

Cours · hier · 3 h — les notions



TP · aujourd'hui · 3 h — la pratique

Se connecter

à une base SQL et NoSQL, sans exposer ses identifiants

.env

PostgreSQL

MongoDB

Interroger

filtrer, agréger, joindre, en SQL et en MQL

SQL

MQL

Extraire proprement

extraction complète ou incrémentale, CSV ou Parquet

pandas

Parquet

Télécharger

des fichiers open data traçables et relançables

requests

DuckDB

Consommer une API

codes HTTP, erreurs, pagination

REST

JSON

Scraper poliment


robots.txt, pauses, cache

BeautifulSoup



Le fil rouge : se connecter → récupérer → enregistrer proprement → croiser les sources.

5 sources, 5 façons de se connecter, un seul mini data lake



💡 Une source, un outil, un notebook – et toujours le même réflexe : garder le brut, livrer du propre.

8 notebooks, 8 demandes concrètes

■ Préparation ■ Bases de données
■ Sources du web : 1 au choix ■ Synthèse


N°	Notebook	La demande (cas d'usage)	Outils	Durée guidée (+ exercices)	Quand
00	Vérifier son poste	« Prouvez que votre poste atteint les 5 sources. »	python-dotenv, psycpg, pymongo, requests	10 min (+ 5)	La veille
01	PostgreSQL en SQL pur	« Un état des lieux 2025-2026 des 24 écoles. »	DataGrip, SQL	35 min (+ 15)	Séance · A
02	PostgreSQL depuis Python	« Les bulletins du 1er trimestre en fichier, et l'export quotidien des nouvelles notes. »	psycpg, pandas, SQLAlchemy	20 min (+ 15)	Séance · B
03	MongoDB depuis Python	« Les 3 chiffres du comité mensuel de l'appli de VTC. »	pymongo, pandas	30 min (+ 15)	Séance · C
04	Fichiers open data · NYC Taxi	« 6 mois de taxis verts, et les jaunes sans les télécharger. »	requests, DuckDB, Parquet	25 min (+ 15)	Atelier D
05	API REST · pagination	« Population et PIB des 8 pays de l'UEMOA, et météo de 5 villes. »	requests, JSON, Parquet	25 min (+ 15)	Atelier D
06	Web scraping poli	« Le catalogue complet d'un concurrent : 1 000 livres. »	requests, BeautifulSoup	20 min (+ 15)	Atelier D
07	Intégration multi-sources	« Un tableau par pays qui croise 3 sources. »	DuckDB, pandas	15 min (+ 15)	Après la séance

Le notebook 01 existe aussi en script pour DataGrip : [sql/01_postgres_datagrip.sql](#)

💡 Chaque notebook suit le même schéma : un cas d'usage → pas à pas → exercices → solutions. © → ☰ → ✎ → ✓

🕒 DÉROULÉ DE LA SÉANCE

3 heures, 4 blocs, 1 atelier au choix



📅 LA VEILLE

notebook 00 · fichier .env · DataGrip installé


💻 démonstration · 💻 vous pratiquez · 👥 en binôme

➔ APRÈS

les 2 ateliers non choisis + notebook 07

💡 Le parcours complet prend environ 5 h : la séance couvre l'essentiel, le reste se fait en autonomie.

Un poste prêt, des secrets bien rangés



Anatomie d'une URI de connexion

`postgresql+psycopg://utilisateur:motdepasse@xxx.pooler.supabase.com:6543/postgres`

le SGBD + le driver Python

les identifiants → **dans .env, jamais dans le code**

l'hôte : le « pooler » Supabase (accessible en IPv4)

le port : mode « transaction », pour toute une classe (le 5432 est limité à 15 clients)

la base

`mongodb+srv://**:*@cluster.xxxxx.mongodb.net/`

+srv : l'adresse exacte est trouvée via le DNS



La check-list du notebook 00


Source	Statut	Temps (s)
PostgreSQL	OK	1,34
MongoDB	OK	1,34
Fichier NYC TLC	OK	0,45
API Banque mondiale	OK	0,42
API Open-Meteo	OK	0,54
Site books.toscrape.com	OK	1,02
Extension DuckDB httpfs	OK	0,04

7 tests OK sur 7 — votre poste est prêt.
temps indicatifs, ils varient selon le réseau

💡 Les identifiants vivent dans .env : jamais dans le code, jamais sur GitHub, jamais dans une sortie de cellule.

Une base relationnelle : un réseau de 24 écoles, de 2019 à 2026

3 pays : France, Bénin, Sénégal	24 écoles (8 par pays)	7 années scolaires : 2019-2020 → 2025-2026	5 549 élèves	1,18 M notes	15 + 2 tables + vues
---	----------------------------------	--	------------------------	------------------------	--------------------------------



À savoir

- ♂ **Clés étrangères** : ni ville sans pays, ni note sans élève.
- 🔑 **Contraintes CHECK** : note ≥ 0 , trimestre de 1 à 3.
- ⚠️ **Autorisé ≠ présent** : « mixte », « examen »... jamais vus.
- 🔒 **Lecture seule**. Données fictives, traitées comme réelles.

💡 Le schéma est imposé à l'écriture : c'est lui qui garantit la qualité de la donnée.

Du premier SELECT au tableau de bord de la direction

bonus
WITH · RANK() · EXPLAIN



Le livrable : 2025-2026 par pays

Pays	Écoles	Classes	Élèves inscrits	Moyenne T1
Bénin	8	66	827	11,00
France	8	57	726	10,83
Sénégal	8	64	656	10,94

Anomalies à signaler : ⚠ 56 classes sans élève ⚠ 12 classes en sureffectif


✅ recoupé : $827 + 726 + 656 = 2\,209$ bulletins du T1

Dans DataGrip

- 🔌 port 6543 · `prepareThreshold = 0`
 - ⌨️ **Ctrl + Entrée** : exécute la requête sous le curseur
 - 📄 **Export Data** → **CSV** : le livrable pour la direction
- Même contenu en notebook : [notebooks/01_postgres_sql.ipynb](#)

💡 SQL est déclaratif : on dit **quoi**, la base trouve **comment**.

Deux façons de lire la base, deux livrables



```

requete = text("SELECT id, prenom, nom FROM eleves "
              "WHERE ville_id = :ville")
eleves = pd.read_sql(requete, engine, params={"ville": 5})
  
```

✓ requête paramétrée

⊘ jamais de f-string dans le SQL (injection)

Bulletins du T1 2025-2026


CSV  218,5 Ko

Parquet  28,9 Ko


Parquet = 13 % du CSV

🛡️ sans e-mail ni téléphone (minimisation, RGPD)

Export incrémental des notes




Lu sur 3 jours



💡 Faire travailler la base : compter d'abord, agréger côté serveur, ne rapatrier que l'utile.

Une base document : une appli de VTC, de livraison et de location dans 19 pays

8 collections	19 pays d'Afrique	335 459 courses	20 247 clients	2 647 chauffeurs	déc. 2023 → déc. 2025 période, en forte croissance
-------------------------	-----------------------------	---------------------------	--------------------------	----------------------------	--



```

{
  "_id": ObjectId("68932b9d..."),
  "serviceType": "delivery",
  "userId": ObjectId("..."),
  "requestedAt": ISODate("2025-09-03T19:29:07Z"),
  "currency": "XOF",
  "amount": 1485.93,
  "fare": { "breakdown": { "base": 317.72, ... } },
  "origin": { "coordinates": [161.69, 0.86] },
  "serviceDetails": {
    "packageWeightKg": 20.69
  }
}
  
```

identifiant unique (contient sa date)

sous-document : le détail du prix

tableau [longitude, latitude]

rempli seulement pour les livraisons : schéma souple

---> ObjectId non imposé par la base

- ⚠ 7 devises (XOF, XAF, NGN, GHS, KES, CDF, SLL) → ne jamais tout additionner
- ⚠ 7 973 villes orphelines sur 8 214 (pays introuvable)
- ⚠ Coordonnées GPS aléatoires
- ⚠ Noms de pays mi-français, mi-anglais (« Bénin », « Senegal ») → code ISO


💡 Un document regroupe ce qu'on lit ensemble — mais « schemaless » ne veut pas dire « sans schéma ».

Les 3 chiffres du directeur, avec un pipeline d'agrégation

SQL ↔ MongoDB

SQL	MongoDB
table	collection
ligne	document
colonne	champ
WHERE	filtre / \$match
GROUP BY	\$group
ORDER BY / LIMIT	\$sort / \$limit
JOIN	\$lookup

Un pipeline, étape par étape



La demande du directeur

- ✓ Courses par mois et par type de service
 - ✓ Chiffre d'affaires de novembre 2025, **par devise**
 - ✓ Note moyenne reçue par les chauffeurs : **3,0 / 5** sur 335459 notes
- `find` `count_documents`
`distinct`
`json_normalize` → `pandas`

💡 Faire calculer le serveur (\$match en premier), et vérifier la véracité avant de livrer.

Fichiers, API ou web : choisissez votre source

04 Fichiers NYC Taxi

« 6 mois de taxis verts, et les jaunes sans les télécharger. »

- 1 télécharger() : URL officielle
- 2 data/raw/ + manifest.json
- 3 SQL DuckDB sur les fichiers

259 469 courses vertes, 6 mois
3 336 716 jaunes lues à distance en **0,6 s**
Parquet : **1,01 Mo** et **4 ms** · CSV : **4,23 Mo** et **206 ms**

Réflexes

dater empreinte garder le brut noter la source

05 API REST

« Population et PIB des 8 pays de l'UEMOA, et météo de 5 villes. »

- 1 GET Banque mondiale, Open-Meteo
- 2 code HTTP : 200 / 404 / 429
- 3 JSON brut (bronze) → Parquet

200 lignes = total annoncé ✓
4 pages × **50** · **2** indicateurs · météo de **5** villes

Réflexes

raise_for_status() « un 200 peut cacher une erreur » 429 → attendre puis réessayer

06 Web scraping

« Le catalogue complet d'un concurrent : 1 000 livres. »

- 1 robots.txt + CGU
- 2 HTML → BeautifulSoup + CSS
- 3 « next » × 50, pause 0,5 s, cache


1 000 livres, dont 196 à 5 étoiles
1re collecte : **91 s** · relance depuis le cache : **2,3 s**

Réflexes

dernier recours poli (User-Agent, pause) fragile (contrôler 20 livres par page)

💡 Règle d'or : une API, sinon un fichier officiel, et le scraping en dernier recours.

Croiser 3 sources dans un seul tableau fiable



La clé de jointure : le code ISO

ISO	MongoDB	PostgreSQL	Banque mondiale
BJ	Bénin	Bénin	Benin
SN	Senegal	Sénégal	Senegal
CI	Côte d'Ivoire	(absent)	Cote d'Ivoire

- ✗ Jointure sur le nom : 14 pays sur 19
perdus : Bénin, Côte d'Ivoire, Tchad, les 2 Congo
- ✓ Sur le code ISO : 19 sur 19

La table gold : 1 ligne par pays

ISO	pays	courses / 100 000 hab.
GQ	Guinée équatoriale	909,7
GW	Guinée-Bissau	772,2
GA	Gabon	704,8
...		
BJ	Bénin	118,8
SN	Sénégal	97,2
FR	France	—

Avant de livrer

- ✓ Unicité
- ✓ Complétude
- ✓ Réconciliation
- ✓ Fraîcheur

Relancer le chargement 2 fois

- INSERT INTO
→ 40 lignes : doublons ✗
- CREATE OR REPLACE
→ 20 lignes : idempotent ✓

💡 Croiser, c'est d'abord choisir la bonne clé — puis contrôler avant de livrer.

Les règles du jeu, et c'est parti

6 règles, pour toute la promo

-  **Lecture seule** : **SELECT**, **find**, **aggregate**.
Jamais d'écriture.
-  **Requêtes légères** : toujours un filtre, une projection ou un **LIMIT**.
-  **Secrets hors du code** : le **.env** ne se committe jamais.
-  **Données personnelles** : fictives, mais on n'exporte ni e-mails ni téléphones.
-  **Collecte polie** : **User-Agent**, pauses, cache ; noter source, licence, date.
-  **Chiffres datés** : vos sorties peuvent différer de celles du dépôt.

 **Bloqué ?** → **notebook 00 §9**
`docs/connexion_datagrip.md`

Évaluation : QCM + séquences

Élément	Points	Ce qu'on rend
QCM (15 questions)	20	sur le cours, en début de séance
A · SQL	20	tableau de bord 2024-2025, en CSV
B · PostgreSQL + Python	15	bulletins du 2e trimestre, en Parquet, sans donnée personnelle
C · MongoDB	20	les 3 chiffres d'octobre 2025
D · Atelier	15	rejoué avec un autre paramètre
Explication	10	« d'où vient la donnée, comment je l'ai vérifiée »
Bonus	+ 5	un chargement idempotent
Total	100	+ 5 de bonus

Les solutions sont dans le dépôt : on note des variantes.

Le dépôt du TP



github.com/abrahamkoloboe27/ama-sources-de-donnees-tp

- notebooks/ 00 → 07
- sql/ script DataGrip
- docs/ plan, schémas
- data/ vide au départ
- .env.example modèle

▶ **À vous de jouer : ouvrez `notebooks/00_verifier_son_poste.ipynb`.**

Les 6 erreurs les plus fréquentes

Où ?	Ce que vous voyez	Cause fréquente	Solution
1 .env	<code>load_dotenv()</code> → <code>False</code> et « MANQUANTE » partout	.env absent ou mal placé	copier .env.example en .env à la racine (pas dans notebooks/), puis redémarrer le noyau
2 PostgreSQL	<code>password authentication failed</code> <code>Tenant or user not found</code>	utilisateur ou mot de passe mal copié	recopier PG_USER et PG_PASSWORD depuis les valeurs reçues, sans espace ni guillemets
3 PostgreSQL	<code>Network is unreachable</code> hôte db.<projet>.supabase.co	hôte direct, joignable seulement en IPv6	prendre l'hôte du pooler donné dans .env
4 PostgreSQL	<code>max clients reached</code>	mode session (port 5432) : 15 clients maximum	passer au port 6543 (mode transaction)
5 PostgreSQL	<code>prepared statement "_pg3_0" already exists</code>	mode transaction sans prepare_threshold=None	l'ajouter à psycpg.connect ; dans DataGrip, prepareThreshold=0
6 MongoDB	<code>ServerSelectionTimeoutError</code>	IP du réseau non autorisée sur Atlas (menu Network Access)	prévenir l'enseignant, ou essayer un autre réseau

Les 9 autres cas (proxy, DNS, extension DuckDB, 429...) : section 9 du notebook 00.

💡 Après toute correction du **.env**, redémarrer le noyau puis tout relancer.



Merci !

Abraham Koloboe · Cloud Data Engineer — questions, retours, idées : écrivez-moi.

✉ abraham.koloboe@gmail.com

👤 [LinkedIn · Abraham Zacharie Koloboe](#)

🔗 github.com/abrahamkoloboe27



AMA sur LinkedIn · linkedin.com/company/bourseama